Leo Giesen, Johannes Kauffmann

VM: Deep Learning mit Python
Case Study: Land Use and Land Cover

Data Access & Exploration

- Shape inspiziert: (10.000, 12, 33, 33, 6)
- Bilder visualisiert: 5 Patches über alle Monate
- Anzahl Trainingsdaten pro Klassen gezählt
- **Klasse 2 ist überrepräsentiert, während Klassen**
- **6, 7 & 10 gar nicht vorhanden sind**

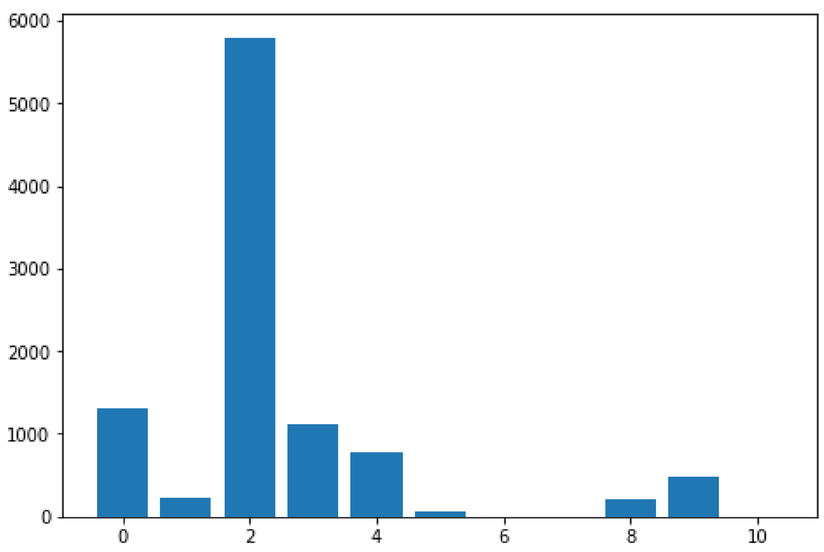

Data Preparation

- **Klassengewichte automatisch ermitteln**

```
# Calculate class weights automatically
class_weights_array = class_weight.compute_class_weight('balanced',
                                                        np.unique(y_train),
                                                        y_train)

# Create dictionary for the class weights
class_weights_dict = {
    0: class_weights_array[0],
    1: class_weights_array[1],
    2: class_weights_array[2],
    3: class_weights_array[3],
    4: class_weights_array[4],
    5: class_weights_array[5],
    6: 0,
    7: 0,
    8: class_weights_array[6],
    9: class_weights_array[7],
    10: 0,
}
```

- Data Augmentation des Trainings-Datensatzes
- In Test, Training & Validations Set aufgeteilt
- 1-hot Encoding

Choosing a Model

- Brauchen ein **3D CNN**, weil es 12 Bilder (Monate) pro Patch gibt

- Loss: (sparse) categorial crossentropy
- Optimierer: Adam
- Metrik: accuracy

```
Model: "sequential"
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
conv3d (Conv3D)              (None, 10, 31, 31, 32)    5216
_________________________________________________________________
max_pooling3d (MaxPooling3D) (None, 5, 15, 15, 32)     0
_________________________________________________________________
batch_normalization (BatchNo (None, 5, 15, 15, 32)     128
_________________________________________________________________
conv3d_1 (Conv3D)            (None, 3, 13, 13, 64)     55360
_________________________________________________________________
max_pooling3d_1 (MaxPooling3 (None, 1, 6, 6, 64)       0
_________________________________________________________________
batch_normalization_1 (Batch (None, 1, 6, 6, 64)       256
_________________________________________________________________
flatten (Flatten)            (None, 2304)              0
_________________________________________________________________
dense (Dense)                (None, 256)               590080
_________________________________________________________________
dense_1 (Dense)              (None, 128)               32896
_________________________________________________________________
dense_2 (Dense)              (None, 64)                8256
_________________________________________________________________
dense_3 (Dense)              (None, 32)                2080
_________________________________________________________________
dense_4 (Dense)              (None, 11)                363
=================================================================
Total params: 694,635
Trainable params: 694,443
Non-trainable params: 192
```

Alternative, die wir erstmal verworfen haben:
Transfer Learning mit vortrainiertem Modell:

- Problem: kein Modell mit vergleichlicher Input-Shape
- Workaround: zwei Modelle für jeweils drei Channel oder Training mit jeweils drei Channeln nacheinander
  → Informationen gehen verloren

Training & Evaluation

Training (fit):
- Mit automatisch ermittelten Klassengewichten
- Callbacks: Early Stopping, Checkpoint
- 60 Epochen

Evaluation:
- **Accuracy: 0.6085 und Loss: 1.1794**

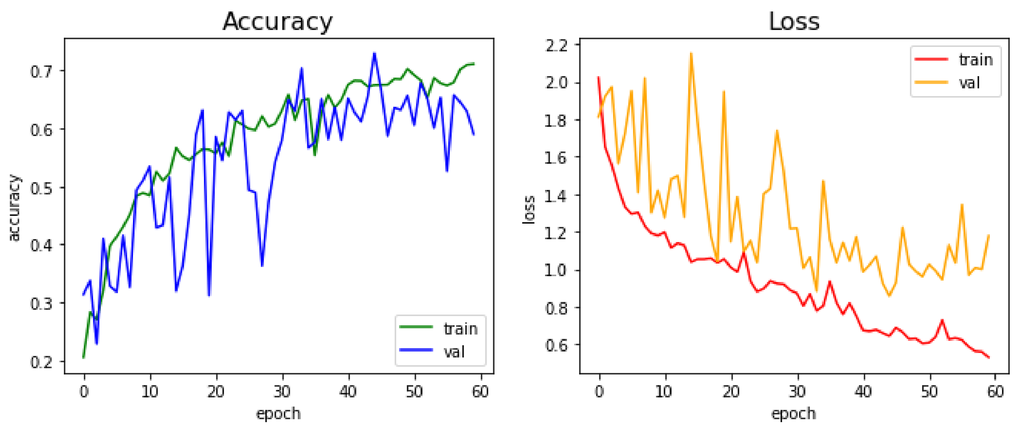

Prediction

- Zero-Padding: 16 Pixel mit Wert 0 um Bild herum
- **Naive Sliding Window**: Iteration über jeden Pixel einzeln
  - Verbesserte Lösungsansätze wie Convolutional Sliding Window Approach?

- Herausforderungen:
  - Dauert sehr lange, v.a. wenn man mit Numpy Arrays arbeitet beim Sliding Window Approach
  - Feine Elemente werden nicht perfekt erkannt
  - Randelemente durch Zero-Padding beeinflusst